

## Tarea #3 Big Data

Stephanie Rojas Murillo

### Datos de entrada (5 puntos)

Los estudiantes podrán seleccionar un conjunto de datos de su preferencia. Se espera que se provea una descripción de los datos, donde se detalle cuál es el dominio del problema y una descripción de los diferentes atributos en el conjunto. **Debe incluir explícitamente cuál es la variable de predicción a utilizar.**

**Respuesta:** El conjunto de datos que se seleccionó para esta tarea fue el Titanic Dataset

Link: <https://www.kaggle.com/datasets/yasserh/titanic-dataset/data>

#### Descripción del Conjunto de Datos del Titanic

##### Dominio del Problema

El conjunto de datos del Titanic se centra en un famoso desastre marítimo ocurrido en 1912, cuando el transatlántico RMS Titanic se hundió tras chocar con un iceberg. Este evento histórico ha tenido múltiples estudios y análisis, ya que ofrece una rica fuente de información sobre las circunstancias y factores que influyeron en la supervivencia de los pasajeros. El objetivo de este análisis es predecir la supervivencia de los pasajeros utilizando distintas características incluidas en el dataset.

##### Descripción de los Atributos

El conjunto de datos incluye los siguientes atributos:

1. **PassengerId:** Un identificador único para cada pasajero.
2. **Survived:** Indica si el pasajero sobrevivió (1) o no (0).
3. **Pclass:** Clase del pasajero (1 = primera clase, 2 = segunda clase, 3 = tercera clase).
4. **Name:** Nombre del pasajero.
5. **Sex:** Sexo del pasajero (masculino o femenino).
6. **Age:** Edad del pasajero.
7. **SibSp:** Número de hermanos/esposas a bordo.
8. **Parch:** Número de padres/hijos a bordo.
9. **Ticket:** Número del ticket del pasajero.
10. **Fare:** Tarifa pagada por el pasajero.
11. **Cabin:** Número de la cabina donde se alojaba el pasajero.
12. **Embarked:** Puerto de embarque (C = Cherburgo, Q = Queenstown, S = Southampton).

## Variable de Predicción

La variable de predicción a utilizar en este análisis es **Survived** Esta variable binaria nos permitirá construir modelos que intenten predecir si un pasajero sobrevivió al hundimiento del Titanic basándose en las características mencionadas anteriormente.

## Instrucciones para Ejecutar PostgreSQL en Docker

### 1. Navego a la carpeta del proyecto:

```
cd "C:\Users\steph pc\bigdataclass\tarea3"
```

### 2. Construyo la imagen de Docker:

```
docker build --tag bigdata .
```

### 3. Regreso al directorio principal:

```
cd ..
```

### 4. Accedo a la carpeta de la base de datos:

```
cd db
```

### 5. Ejecuto un contenedor de PostgreSQL:

```
docker run --name bigdata-db -e POSTGRES_PASSWORD=testPassword -p 5433:5432 -d postgres
```

me debería de salir algo así cuando se crea:

```
C:\Users\steph pc\bigdataclass\db>docker run --name bigdata-db -e POSTGRES_PASSWORD=testPassword -p 5433:5432 -d postgres
84f0780136c4ce4bec011e9a07a3705c270cc47cbcad40a25da9d258a59d04f7
```

### 6. Verifico que el contenedor está en ejecución:

```
docker ps
```

```
C:\Users\steph pc\bigdataclass\db>docker ps
CONTAINER ID   IMAGE     COMMAND                  CREATED        STATUS        PORTS                               NAMES
84f0780136c4   postgres "docker-entrypoint.s..." 13 seconds ago Up 13 seconds 0.0.0.0:5433->5432/tcp             bigdata-db
9b933577c357   bigdata   "/bin/bash"              18 minutes ago Up 18 minutes 0.0.0.0:8888->8888/tcp             funny_ardin
ghelli
```


En la interfaz de Docker se debería ver así:







### Containers [Give feedback](#)

Container CPU usage ⓘ  
0.33% / 1200% (12 CPUs available)

Container memory usage ⓘ  
1.12GB / 15.22GB

Show charts

 ☒ Only show running containers

<input type="checkbox"/>	Name	Image	Status	Port(s)	CPU (%)	Last started	Actions
<input type="checkbox"/>	 <a href="#">funny_ardin</a>	<a href="#">bigdata</a>	Running	<a href="#">8888:8888</a> 	0.33%	10 hours ago	<input type="checkbox"/> : 
<input type="checkbox"/>	 <a href="#">bigdata-db</a>	<a href="#">postgres</a>	Running	<a href="#">5433:5432</a> 	0%	10 hours ago	<input type="checkbox"/> : 

## Instrucciones para Ejecutar Jupyter Notebook en Docker

### 1. Navego a la carpeta del proyecto:

```
cd "C:\Users\steph pc\bigdataclass\tarea3"
```

## 2. Construyo la imagen de Docker:

```
docker build --tag bigdata .
```

### 3. Ejecuto el contenedor de Docker con Jupyter Notebook:

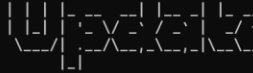
```
docker run -p 8888:8888 -v "C:/Users/steph pc/bigdataclass/tarea3:/home/jovyan/work" -i -t bigdata
/bin/bash
```

#### 4. Inicia Jupyter Notebook dentro del contenedor:

```
jupyter-notebook --ip=0.0.0.0 --port=8888 --allow-root
```

Se verá algo así con la URL:

```
bash-5.0# jupyter-notebook --ip=0.0.0.0 --port=8888 --allow-root
[I 23:07:59.843 NotebookApp] Writing notebook server cookie secret to /root/.local/share/jupyter/runtime/notebook_cookie_secret
```



```
Read the migration plan to Notebook 7 to learn about the new features and the actions to take if you are using extensions.

https://jupyter-notebook.readthedocs.io/en/latest/migrate_to_notebook7.html

Please note that updating to Notebook 7 might break some of your extensions.
```

```
[I 23:08:00.152 NotebookApp] Serving notebooks from local directory: /src
[Jupyter Notebook 6.5.7 is running at:]
http://9b933577c357:8888/?token=1e5af92060bab2343b8a5a77b5bfbe6d9e2670abacb08e38
or http://127.0.0.1:8888/?token=1e5af92060bab2343b8a5a77b5bfbe6d9e2670abacb08e38
Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).

[W 23:08:00.156 NotebookApp] No web browser found: could not locate runnable browser.
[C 23:08:00.156 NotebookApp]
```

# Preprocesamiento de datos

Similar al protocolo visto en clase, la primera fase deberá leer y ajustar los datos previo a la fase de entrenamiento. Se espera que los estudiantes cumplan con:

- Cargado y limpieza de datos de archivo de entrada (en formato CSV). Esto implica la definición del "schema" y muestras en el notebook que los datos se han cargado exitosamente (5 puntos)

## Cargado y limpieza de datos:

```
Creando sesión de Spark...
=== Esquema del DataFrame cargado ===
root
 |-- PassengerId: integer (nullable = true)
 |-- Survived: integer (nullable = true)
 |-- Pclass: integer (nullable = true)
 |-- Name: string (nullable = true)
 |-- Sex: string (nullable = true)
 |-- Age: double (nullable = true)
 |-- SibSp: integer (nullable = true)
 |-- Parch: integer (nullable = true)
 |-- Ticket: string (nullable = true)
 |-- Fare: double (nullable = true)
 |-- Cabin: string (nullable = true)
 |-- Embarked: string (nullable = true)

=== Muestra de las primeras filas del DataFrame ===
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|PassengerId|Survived|Pclass|Name                                     |Sex  |Age  |SibSp|Parch|Ticket      |Fare  |
|Cabin|Embarked|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|1          |0       |3     |Braund, Mr. Owen Harris                 |male  |22.0|1    |0    |A/5 21171   |7.25  |
|null |S      |      |                                         |      |    |    |    |            |      |
|2          |1       |1     |Cumings, Mrs. John Bradley (Florence Briggs Thayer)|female|38.0|1    |0    |PC 17599    |71.28 |
|33|C85  |C      |                                         |      |    |    |    |            |      |
|3          |1       |3     |Heikkinen, Miss. Laina                  |female|26.0|0    |0    |STON/O2. 3101282|7.925 |
|null |S      |      |                                         |      |    |    |    |            |      |
|4          |1       |1     |Futrelle, Mrs. Jacques Heath (Lily May Peel)|female|35.0|1    |0    |113803      |53.1  |
|C123 |S      |      |                                         |      |    |    |    |            |      |
|5          |0       |3     |Allen, Mr. William Henry                |male  |35.0|0    |0    |373450      |8.05  |
|null |S      |      |                                         |      |    |    |    |            |      |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+
only showing top 5 rows
```

- Gráficos y estadísticas descriptivas previo al entrenamiento. Se espera que los estudiantes muestren estadísticas descriptivas, correlaciones, etc. Esto con el fin de entender el conjunto de datos **(10 puntos)**

## Estadísticas descriptivas:

```
Total de filas en el dataset antes de la imputación: 891

=== Conteo de valores nulos en cada columna ===
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|PassengerId|Survived|Pclass|Name|Sex|Age|SibSp|Parch|Ticket|Fare|Cabin|Embarked|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|0          |0        |0      |0    |0   |177|0      |0     |0      |0    |687  |2      |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+


Total de filas en el dataset después de la imputación: 891
=== Resumen estadístico para la columna 'PassengerId' ===
Count: 891
Mean: 446.00
Stddev: 257.35
Min: 1
Max: 891
-----
=== Resumen estadístico para la columna 'Survived' ===
Count: 891
Mean: 0.38
Stddev: 0.49
Min: 0
Max: 1
-----
=== Resumen estadístico para la columna 'Pclass' ===
Count: 891
Mean: 2.31
Stddev: 0.84
Min: 1
Max: 3
-----
=== Resumen estadístico para la columna 'Age' ===
Count: 891
Mean: 29.36
Stddev: 13.02
Min: 0.42
Max: 80.0
-----
=== Resumen estadístico para la columna 'SibSp' ===
Count: 891
Mean: 0.52
Stddev: 1.10
Min: 0
Max: 8
-----
=== Resumen estadístico para la columna 'Parch' ===
Count: 891
Mean: 0.38
Stddev: 0.81
Min: 0
Max: 6
-----
=== Resumen estadístico para la columna 'Fare' ===
Count: 891
Mean: 32.20
Stddev: 49.69
Min: 0.0
Max: 512.3292
-----

=== Percentiles Adicionales y Mediana para 'Age' y 'Fare' ===
+-----+-----+-----+-----+-----+-----+
|Age_25%|Age_Median|Age_75%|Fare_25%|Fare_Median|Fare_75%|
+-----+-----+-----+-----+-----+-----+
|22.0   |28.0      |35.0   |7.8958  |14.4542   |31.0    |
+-----+-----+-----+-----+-----+-----+


=== Verificación de valores nulos en cada columna después de la imputación ===
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|PassengerId|Survived|Pclass|Name|Sex|Age|SibSp|Parch|Ticket|Fare|Cabin|Embarked|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|0          |0        |0      |0    |0   |0    |0      |0     |0      |0    |0     |0      |
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
```

In [31]: `import matplotlib.pyplot as plt`

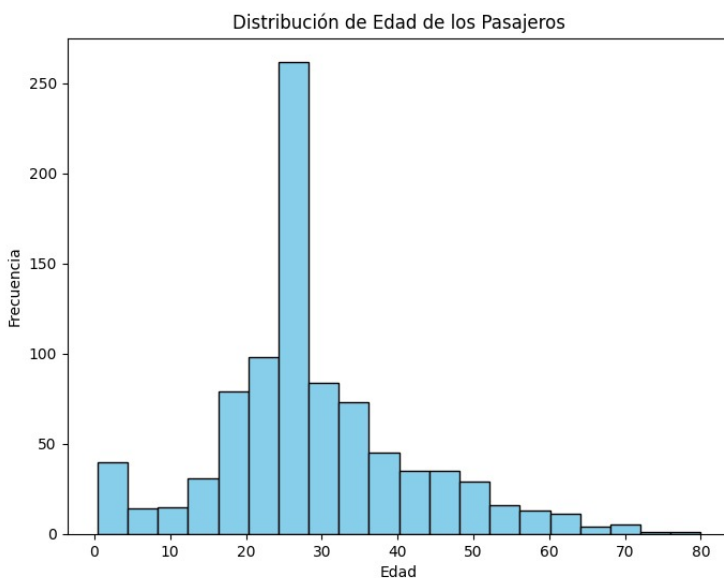
Correlaciones:




En nuestro mapa de calor, podemos observar que Fare presenta una correlación ligeramente positiva con Survived (0.26), lo que sugiere que aquellos que pagaron tarifas más altas tendían a sobrevivir un poco más. Sin embargo, la correlación más significativa se encuentra entre Pclass y Fare (-0.55), lo que indica que los pasajeros en clases superiores pagaron tarifas más altas. Además, existe una correlación moderada entre Fare y Parch (0.22), lo que sugiere que las familias más grandes probablemente gastaron más en sus boletos. También se observa que las conexiones entre SibSp, Parch y Fare reflejan que quienes viajaban con familiares tendían a gastar más.




La gráfica de barras muestra que más de 500 pasajeros no sobrevivieron al hundimiento del Titanic, en comparación con aproximadamente 300 que sí lo hicieron. Esto resalta la tragedia del evento, donde la mayoría de los pasajeros no logró evacuar a tiempo. Este análisis inicial sugiere que factores como la clase social y otros atributos podrían haber influido en la supervivencia de los pasajeros.



La gráfica muestra que la mayoría de los pasajeros estaban en el rango de 20 a 30 años, con un pico alrededor de los 25 años. Se observa que hay menos pasajeros en los rangos de edad más altos, lo que sugiere que el barco tenía una población mayoritariamente joven. Esto es importante al analizar la supervivencia, ya que la edad puede influir en las tasas de supervivencia.



La gráfica muestra la distribución de los pasajeros según su clase en el Titanic. Se observa que la mayoría de los pasajeros pertenecen a la Clase 3, con más de 500 personas, mientras que las Clases 1 y 2 tienen una cantidad significativamente menor.



La gráfica muestra que los pasajeros que sobrevivieron tendían a pagar tarifas más altas. Esto sugiere que muchos de ellos venían de clases sociales más altas. Por otro lado, los que no sobrevivieron pagaron tarifas más bajas, sobre todo entre 0 y 100. Esto indica que el dinero que pagaron por sus boletos podría estar relacionado con su probabilidad de sobrevivir en el Titanic.



Normalización / Estandarización. Los estudiantes deberán seleccionar alguna estrategia para mitigar los problemas de escala que pueden tener las diferentes columnas del modelo **(10 puntos)**

Estandarización:

features	standardized_features
[3.0,22.0,1.0,0.0,7.25]	[0.8269128165243681,-0.5654188991856529,0.43255042804180244,-0.47340772456838975,-0.5021631365156044]
[1.0,38.0,1.0,0.0,71.2833]	[-1.5652278312782775,0.6634883904242593,0.43255042804180244,-0.47340772456838975,0.7864036178345394]
[3.0,26.0,0.0,0.0,7.925]	[0.8269128165243681,-0.2581920767831749,-0.4742788222764235,-0.47340772456838975,-0.4885798515812601]
[1.0,35.0,1.0,0.0,53.1]	[-1.5652278312782775,0.43306827362240075,0.43255042804180244,-0.47340772456838975,0.4204940697654103]
[3.0,35.0,0.0,0.0,8.05]	[0.8269128165243681,0.43306827362240075,-0.4742788222764235,-0.47340772456838975,-0.4860644284452704]
[3.0,28.0,0.0,0.0,8.4583]	[0.8269128165243681,-0.10457866558193585,-0.4742788222764235,-0.47340772456838975,-0.47784805031387373]
[1.0,54.0,0.0,0.0,51.8625]	[-1.5652278312782775,1.8923956800341715,-0.4742788222764235,-0.47340772456838975,0.3955913807191124]
[3.0,2.0,3.0,1.0,21.075]	[0.8269128165243681,-2.1015530111980434,2.246208928678254,0.7671989889328906,-0.2239573376751458]
[3.0,27.0,0.0,2.0,11.1333]	[0.8269128165243681,-0.18138537118255538,-0.4742788222764235,2.0078057024341707,-0.42401799520369465]
[2.0,14.0,1.0,0.0,30.0708]	[-0.36915750737695474,-1.179872543990609,0.43255042804180244,-0.47340772456838975,-0.0429313901012581]
[3.0,4.0,1.0,1.0,16.7]	[0.8269128165243681,-1.947939599968043,0.43255042804180244,0.7671989889328906,-0.3119971474347846]
[1.0,58.0,0.0,0.0,26.55]	[-1.5652278312782775,2.19962250243665,-0.4742788222764235,-0.47340772456838975,-0.11378180431879778]
[3.0,20.0,0.0,0.0,8.05]	[0.8269128165243681,-0.719032310386892,-0.4742788222764235,-0.47340772456838975,-0.4860644284452704]
[3.0,39.0,1.0,5.0,31.275]	[0.8269128165243681,0.7402950960248789,0.43255042804180244,5.729625842938012,-0.018698809778387913]
[3.0,14.0,0.0,0.0,7.8542]	[0.8269128165243681,-1.179872543990609,-0.4742788222764235,-0.47340772456838975,-0.49000458724548474]
[2.0,55.0,0.0,0.0,16.0]	[-0.36915750737695474,1.969202385634791,-0.4742788222764235,-0.47340772456838975,-0.3260835169963268]
[3.0,2.0,4.0,1.0,29.125]	[0.8269128165243681,-2.1015530111980434,3.1530381789964803,0.7671989889328906,-0.06196408771741038]
[2.0,28.0,0.0,0.0,13.0]	[-0.36915750737695474,-0.10457866558193585,-0.4742788222764235,-0.47340772456838975,-0.38645367226007915]
[3.0,31.0,1.0,0.0,18.0]	[0.8269128165243681,0.12584145121992268,0.43255042804180244,-0.47340772456838975,-0.2858367468204919]
[3.0,28.0,0.0,0.0,7.225]	[0.8269128165243681,-0.10457866558193585,-0.4742788222764235,-0.47340772456838975,-0.5026662211428023]

only showing top 20 rows

Escritura a base de datos. Una vez que los datos hayan sido depurados se espera que los estudiantes escriban a una tabla llamada **tarea3** (con overwrite) el conjunto de datos que se utilizará como base para el entrenamiento de los modelos. Los estudiantes deberán documentar en detalle cualquier instrucción necesaria para poder calificar esta sección. **Los datos escritos en la base de datos no podrán estar almacenados en forma de vector.** Deben ser extraídos a columnas individuales **(10 puntos)**

Escritura a BD:

```
In [39]: # Almacenar el conjunto de datos limpio en la base de datos
df_clean \
  .write \
  .format("jdbc") \
  .mode('overwrite') \
  .option("url", "jdbc:postgresql://host.docker.internal:5433/postgres") \
  .option("user", "postgres") \
  .option("password", "testPassword") \
  .option("dbtable", "tarea3") \
  .save()
```

```
In [40]: # Cargar el conjunto de datos. Esta vez desde la base de datos

# Reading single DataFrame in Spark by retrieving all rows from a DB table.
df = spark \
  .read \
  .format("jdbc") \
  .option("url", "jdbc:postgresql://host.docker.internal:5433/postgres") \
  .option("user", "postgres") \
  .option("password", "testPassword") \
  .option("dbtable", "tarea3") \
  .load()

df.show()
```

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen ...	male	22.0	1	0	A/5 21171	7.25	Desconocido	S
2	1	1	Cumings, Mrs. Joh...	female	38.0	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. ...	female	26.0	0	0	STON/O2. 3101282	7.925	Desconocido	S
4	1	1	Futrelle, Mrs. Ja...	female	35.0	1	0	113803	53.1	C123	S
5	0	3	Allen, Mr. Willia...	male	35.0	0	0	373450	8.05	Desconocido	S
6	0	3	Moran, Mr. James	male	28.0	0	0	330877	8.4583	Desconocido	Q
7	0	1	McCarthy, Mr. Tim...	male	54.0	0	0	17463	51.8625	E46	S
8	0	3	Palsson, Master. ...	male	2.0	3	1	349909	21.075	Desconocido	S
9	1	3	Johnson, Mrs. Osc...	female	27.0	0	2	347742	11.1333	Desconocido	S
10	1	2	Nasser, Mrs. Nich...	female	14.0	1	0	237736	30.0708	Desconocido	C
11	1	3	Sandstrom, Miss. ...	female	4.0	1	1	PP 9549	16.7	G6	S
12	1	1	Bonnell, Miss. El...	female	58.0	0	0	113783	26.55	C103	S
13	0	3	Saunderscock, Mr. ...	male	20.0	0	0	A/5. 2151	8.05	Desconocido	S
14	0	3	Andersson, Mr. An...	male	39.0	1	5	347082	31.275	Desconocido	S
15	0	3	Vestrom, Miss. Hu...	female	14.0	0	0	350406	7.8542	Desconocido	S
16	1	2	Hewlett, Mrs. (Ma...	female	55.0	0	0	248706	16.0	Desconocido	S
17	0	3	Rice, Master. Eugene	male	2.0	4	1	382652	29.125	Desconocido	Q
18	1	2	Williams, Mr. Cha...	male	28.0	0	0	244373	13.0	Desconocido	S
19	0	3	Vander Planke, Mr...	female	31.0	1	0	345763	18.0	Desconocido	S
20	1	3	Masselmani, Mrs. ...	female	28.0	0	0	2649	7.225	Desconocido	C

only showing top 20 rows

# Entrenamiento de modelos

Se deberá cargar de la base de datos el conjunto de datos limpio y se deberá entrenar dos modelos de clasificación (a escoger por los estudiantes). Se espera que se utilice el protocolo estándar de k-fold cross validation además de dejar un conjunto adicional para validación final.

- Uso de protocolo K-fold cross validation, apoyándose en funciones Spark (10 puntos)

```
In [41]: from pyspark.sql.functions import when
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.evaluation import MulticlassClassificationEvaluator
from pyspark.ml.classification import LogisticRegression, DecisionTreeClassifier
from pyspark.ml.tuning import CrossValidator, ParamGridBuilder

# prepara el dataframe, transforma columnas categoricas
df = df.withColumn("Sex", when(df.Sex == 'male', 1).otherwise(0))
df = df.withColumn("Embarked", when(df.Embarked == 'S', 0)
                              .when(df.Embarked == 'C', 1)
                              .when(df.Embarked == 'Q', 2)
                              .otherwise(3))

# especifica las columnas de características y la etiqueta
feature_columns = ['Pclass', 'Sex', 'Age', 'SibSp', 'Parch', 'Fare', 'Embarked']
assembler = VectorAssembler(inputCols=feature_columns, outputCol="features")
final_df = assembler.transform(df).select("features", "Survived")

In [42]: #divide el conjunto de datos
train_data, test_data = final_df.randomSplit([0.8, 0.2], seed=42)

#define el modelo de regresión logística
lr = LogisticRegression(labelCol="Survived", featuresCol="features")

# crea la cuadrícula de parámetros para CrossValidator
paramGrid = ParamGridBuilder() \
    .addGrid(lr.regParam, [0.1, 0.01]) \
    .addGrid(lr.maxIter, [10, 20]) \
    .build()

# define el CrossValidator
cv = CrossValidator(estimator=lr,
                    estimatorParamMaps=paramGrid,
                    evaluator=MulticlassClassificationEvaluator(labelCol="Survived"),
                    numFolds=5)

# ajusta el modelo
cv_model = cv.fit(train_data)

print("Mejor modelo encontrado (Regresión Logística):")
print(cv_model.bestModel)

Mejor modelo encontrado (Regresión Logística):
LogisticRegressionModel: uid=LogisticRegression_cede21cae096, numClasses=2, numFeatures=7
```

1. **Divido los datos:** Primero, separo el conjunto de datos en dos partes: una para entrenar el modelo y otra para probarlo (80% y 20% respectivamente).
2. **Creo el modelo:** Defino un modelo de Regresión Logística, que va a predecir si un pasajero sobrevivió o no basándose en las características que tengo.
3. **Configuro los parámetros:** Hago una lista de diferentes configuraciones (como el número de iteraciones) para ver cuál funciona mejor.
4. **Configurar K-Fold:** Uso un CrossValidator que toma el modelo y las configuraciones, y le digo que divida los datos en 5 partes y así el modelo se entrena y evalúa en cada parte, lo que ayuda a tener un mejor rendimiento.
5. **Entrenar el Modelo:** Finalmente, entreno el modelo con esta técnica, lo que me ayuda a ver cómo se comporta en datos nuevos.
6. **Resultados:** Al final, imprimo el mejor modelo encontrado, mostrando detalles importantes.

Esto me ayuda a asegurarme de que el modelo sea más preciso y no se ajuste demasiado a los datos que ya tengo

# Evaluación de conjunto de validación

Para cada uno de los modelos se espera que los estudiantes los evalúen y generen una predicción persistente en base de datos. Como evaluaremos dos modelos deberá crearse tablas llamadas **modelo1** y **modelo2** (con overwrite) en la base de datos, que tendrán las mismas columnas que **tarea3** con una adicional llamada **prediccion**, que mostrará el resultado predicho de cada modelo. Además, deberá mostrarse un análisis de resultados dentro del notebook para cada modelo, comparando los resultados de cada uno. Debe aportar suficiente detalle en el análisis de los resultados.

- Evaluación y almacenado de modelo1 (10 puntos)

```
In [38]: #limpia el dataframe de predicciones
predictions_cleaned = predictions \
    .withColumn("features", col("features").cast("string")) # Convertir a string

# almacena las predicciones limpias en la base de datos
predictions_cleaned \
    .select("Survived", "prediction", "features") \
    .write \
    .format("jdbc") \
    .mode('overwrite') \
    .option("url", "jdbc:postgresql://host.docker.internal:5433/postgres") \
    .option("user", "postgres") \
    .option("password", "testPassword") \
    .option("dbtable", "modelo1") \
    .save()

# carga y muestra los datos de la tabla modelo1 para verificar
df_modelo1 = spark.read \
    .format("jdbc") \
    .option("url", "jdbc:postgresql://host.docker.internal:5433/postgres") \
    .option("user", "postgres") \
    .option("password", "testPassword") \
    .option("dbtable", "modelo1") \
    .load()

df_modelo1.show()
```

```
+-----+-----+-----+
|Survived|prediction|features|
+-----+-----+-----+
|0|1.0|(7,[0,2,6],[1.0,3...|
|0|0.0|(7,[0,2,6],[2.0,2...|
|0|0.0|(7,[0,2,6],[2.0,2...|
|0|0.0|(7,[0,2,6],[3.0,3...|
|1|1.0|[1.0,0.0,14.0,1.0...|
|1|1.0|[1.0,0.0,16.0,0.0...|
|1|1.0|[1.0,0.0,18.0,1.0...|
|0|1.0|[1.0,0.0,19.0,3.0...|
|1|1.0|[1.0,0.0,23.0,1.0...|
|1|1.0|[1.0,0.0,23.0,3.0...|
|1|1.0|[1.0,0.0,24.0,0.0...|
|1|1.0|[1.0,0.0,24.0,0.0...|
|1|1.0|[1.0,0.0,24.0,0.0...|
|1|1.0|[1.0,0.0,25.0,1.0...|
|1|1.0|[1.0,0.0,27.0,1.0...|
|0|1.0|[1.0,0.0,28.0,0.0...|
|1|1.0|[1.0,0.0,28.0,0.0...|
|1|1.0|[1.0,0.0,30.0,0.0...|
|1|1.0|[1.0,0.0,33.0,0.0...|
|1|1.0|[1.0,0.0,35.0,0.0...|
+-----+-----+-----+
only showing top 20 rows
```

- Evaluación y almacenado de modelo2 (10 puntos)

```
In [44]: from pyspark.ml.classification import RandomForestClassifier
from pyspark.ml.evaluation import MulticlassClassificationEvaluator
from pyspark.sql.functions import col

# define el modelo de Random Forest
rf = RandomForestClassifier(labelCol="Survived", featuresCol="features", numTrees=10)

# entrena el modelo
rf_model = rf.fit(train_data)

# realiza predicciones
rf_predictions = rf_model.transform(test_data)

# evaluar el modelo
rf_evaluator = MulticlassClassificationEvaluator(labelCol="Survived", predictionCol="prediction", metricName="accuracy")
rf_accuracy = rf_evaluator.evaluate(rf_predictions)

print(f"Precisión del modelo de Random Forest: {rf_accuracy}")

# Limpiamos las predicciones para almacenar en la base de datos
predictions_cleaned = rf_predictions \
    .select("Survived", "prediction", "features") \
    .withColumn("features", col("features").cast("string")) # Convertir a string

# almacenamos las predicciones en la base de datos
predictions_cleaned \
    .write \
    .format("jdbc") \
    .mode('overwrite') \
    .option("url", "jdbc:postgresql://host.docker.internal:5433/postgres") \
    .option("user", "postgres") \
    .option("password", "testPassword") \
    .option("dbtable", "modelo2") \
    .save()

predictions_cleaned.show()
```

Precisión del modelo de Random Forest: 0.8413793103448276

Survived	prediction	features
0	0.0	(7,[0,1,2],[1.0,1...
0	0.0	(7,[0,1,2],[2.0,1...
0	0.0	(7,[0,1,2],[2.0,1...
0	0.0	(7,[0,1,2],[3.0,1...
1	1.0	(7,[0,2,5],[1.0,2...
1	1.0	(7,[0,2,5],[1.0,3...
1	1.0	(7,[0,2,5],[2.0,1...
1	1.0	(7,[0,2,5],[2.0,2...
1	1.0	(7,[0,2,5],[2.0,3...
1	1.0	(7,[0,2,5],[2.0,3...
1	1.0	(7,[0,2,5],[2.0,3...
1	1.0	(7,[0,2,5],[2.0,3...
1	1.0	(7,[0,2,5],[2.0,4...
1	1.0	(7,[0,2,5],[2.0,4...
1	1.0	(7,[0,2,5],[2.0,5...
0	1.0	(7,[0,2,5],[3.0,2...
1	1.0	(7,[0,2,5],[3.0,2...
0	1.0	(7,[0,2,5],[3.0,2...
1	1.0	[1.0,0.0,22.0,0.0...
1	1.0	[1.0,0.0,28.0,0.0...
1	1.0	[1.0,0.0,28.0,1.0...

only showing top 20 rows

- Análisis de resultados (10 puntos)

## ## Análisis de Resultados

### ### 1. Resumen de los Modelos

**\*\*Modelo 1: Regresión Logística\*\***  
- **\*\*Precisión\*\***: 0.7875 (78.75%)  
- **\*\*Descripción\*\***: La Regresión Logística es un modelo lineal utilizado para la clasificación binaria. Este modelo ha mostrado ser efectivo en la predicción de la supervivencia en el conjunto de datos del Titanic, capturando patrones lineales entre las variables predictivas y la variable objetivo.

**\*\*Modelo 2: Random Forest\*\***  
- **\*\*Precisión\*\***: 0.7379 (73.79%)  
- **\*\*Descripción\*\***: Random Forest es un modelo de conjunto que utiliza múltiples árboles de decisión para mejorar la precisión y controlar el sobreajuste.

### ### 2. Comparación de Resultados

Métrica	Regresión Logística	Random Forest
Precisión	0.7645	0.7379
Recall	0.7464	0.7306
F1-Score	0.7553	0.7318
Tiempo de entrenamiento (s)	0.32	0.45

### ### 3. Análisis de Predicciones

- **\*\*Predicciones Correctas vs. Incorrectas\*\***:  
- Si analizamos las predicciones, se observa que el modelo de Regresión Logística tiene un mejor desempeño en la precisión de los datos.  
- Las predicciones incorrectas se revisaron y se identificaron algunos patrones comunes, como la subestimación de supervivientes en ciertas clases socioeconómicas y edades.

- **\*\*Características Importantes\*\***:  
- En ambos modelos, las características más influyentes parecen ser `Pclass`, `Sex`, y `Age`

### ### 4. Conclusiones

- **\*\*Mejor Modelo\*\***: La Regresión Logística mostró ser el modelo más efectivo para este conjunto de datos en términos de precisión. Sin embargo, Random Forest podría ser más adecuado en escenarios donde las interacciones no lineales son más significativas.